

Titanic Survival Classification

SAUSAU predmetni projekat

Opis problema

Pretpostavlja se strateško rešavanje zadatka klasifikacije u kojem će biti predviđeno preživljavanje putnika (*survived* / *not survived*) na osnovu demografskih, porodičnih i putnih karakteristika. Dataset sadrži informacije o putnicima na Titaniku, a očekuje se da model omogući identifikaciju faktora koji su imali najznačajniji uticaj na preživljavanje. Poseban naglasak se stavlja na sposobnost analize, interpretacije i vizualnog predstavljanja podataka uz minimalni skup resursa - isključivo *train.csv*.

Pregled kolona i njihovo značenje

Dataset (*train.csv*) obuhvata **sledeće kolone**, svaka sa specifičnim značenjem:

- **PassengerId** - jedinstveni identifikator svakog putnika, korišćen za praćenje.
- **Survived** - **ciljana promenljiva** označena vrednostima 0 (nije preživeo) i 1 (preživeo).
- **Pclass** - klasa karte (1 = prva, 2 = druga, 3 = treća), funkcioniše kao pokazatelj socio-ekonomske pozicije.
- **Name** - puno ime putnika, iz kojeg se može izvesti titula (npr. "Mr.", "Mrs.").
- **Sex** - pol putnika (male / female), značajan demografski faktor.
- **Age** - starost u godinama; ponekad izražena kao decimalna vrednost (npr. 0.5 za bebe).
- **SibSp** - broj braće/supružnika koji su bili na brodu (uz striktno definisane relacije).
- **Parch** - broj roditelja/dece na brodu (uz definisane kategorije kao što su majka, otac, dete).

- **Ticket** - broj karte, koji može sadržati informacije o tipu ili grupi putnika.
- **Fare** - cena karte, izražena u britanskim funtama, ukazuje na platežnu moć i položaj.
- **Cabin** - broj kabine, često nepotpun i korišćen kao potencijalni indikator dodate vrednosti (npr. blizina palube).
- **Embarked** - luka ukrcavanja (C = Cherbourg, Q = Queenstown, S = Southampton), može ukazivati na geografske i društvene obrasce.

Očekivani izlazi (output):

- **Evaluacija modela klasifikacije** obuhvata diskretan prikaz performansi kroz metrike: *tačnost*, *preciznost*, *odziv* i *F1-skor*.
- **Vizualna analiza** najuticajnijih atributa (feature importance) koja će biti jasno predstavljena grafički.
- Grafički prikazi **odnosa između atributa i rezultata** (npr. raspodela starosti, preživljavanje po klasi, polu i slično).
- **Uključeno tumačenje rezultata**: koje karakteristike se najjače povezuju sa preživljavanjem i koje su preporuke za eventualno dalje unapređenje modela.

Zahtevi za procesiranje podataka:

- **Nedostajući podaci** u kolonama poput *Age*, *Cabin* i *Embarked* treba da budu obrađeni na način koji minimizira njihov negativan uticaj na performanse modela.
- **Kategorijski atributi** (*Sex*, *Embarked*, *Pclass*) trebaju da budu prikazani u formatu prikladnom za model, a razlog primene odabrane obrade treba da bude dat.
- **Odluke o uklanjanju ili transformaciji** kolona kao što su *Name*, *Ticket*, *Cabin*, ili eventualna ekstrakcija dodatnih informacija (npr. titule iz *Name*) moraju biti opravdane.

Dokumentovanje rezultata:

- **Rezultati modela i vizuelni elementi** (grafici, tabele) treba da budu prikazani jasno, u formatu pogodno za integraciju u dokumentaciju.
- **Interpretacije i zaključci** moraju biti jasni i logično utemeljeni, uz preporuke za potencijalna poboljšanja.